

1. Download & Clone the project

- Download directly
 - https://github.com/Huigz/dcinside_post_crawler/archive/refs/heads/main.zip
 - 다운로드가 완료되면 **dcinside_post_crawler-main.zip** 파일을 로컬에 압축 해제(Unzip)해 주세요.
- Or Use Git and clone the project in bash

```
git clone
https://github.com/Huigz/dcinside_post_crawler.git
```

Unzip/ Clone한 후의 프로젝트 구조는 다음과 같다

dcinside_post_crawler-main (or dcinside_post_crawler)/

```
├── dcinside_scrapy/
│   ├── init.py
│   ├── items.py      # 데이터 모델 정의
│   ├── middlewares.py # 미들웨어 (이 프로젝트에서 미사용)
│   ├── pipelines.py   # 데이터 처리 파이프라인 (이 프로젝트에서 미사용)
│   ├── settings.py    # 프로젝트 설정
│   └── spiders/       # 크롤러 디렉토리
│       ├── init.py
│       └── dcinside_spider.py # 메인 크롤러 파일
├── scrapy.cfg         # Scrapy 설정 파일
└── README.md
```

2. Open Terminer & Commend Line

2.1. 프로젝트 경로로 이동

```
cd path_of_your_project
```

① Note

압축을 해제(Unzip)한 파일의 경로가 /Users/jmsu/Downloads/main 이라고 가정하면

```
cd /Users/jmsu/Downloads/main/
```

```
[(base) → ~ cd /Users/jmsu/Downloads/main ]
[(base) → main ls ]
README.md      dcinside_scrapy requirements.txt
data           example_result.csv scrapy.cfg
```

2.2. 실행에 필요할 python packages 설치

```
pip install -r requirements.txt
```

```
▶(weibo) → dcinside_scrapy git:(main) conda list pandas
# packages in environment at /Users/jmsu/anaconda/anaconda3/envs/weibo:
#
# Name          Version          Build      Channel
pandas          2.2.2            pypi_0     pypi
▶(weibo) → dcinside_scrapy git:(main) conda list scrapy
# packages in environment at /Users/jmsu/anaconda/anaconda3/envs/weibo:
#
# Name          Version          Build      Channel
scrapy          2.11.2           pypi_0     pypi
```

3. Put your url.csv File in data folder

① Note

프로젝트 에는 이미 예제 url.csv 파일이 존재하며, 위치는 다음과 같다

- data/urls.csv

Scrapy는 urls.csv 파일의 url 열 데이터를 순차적으로 추가하고, 각 URL에 대해 자동으로 서버에게 요청을 보냅니다. 이때, urls.csv 파일은 다음과 같은 요구 사항을 반드시 충족해야 한다.

1. 파일 형식

- 파일명: `urls.csv`
- 인코딩: UTF-8
- 구분자: 콤마(,)

2. 필수 열

CSV 파일은 반드시 다음 세 개의 열(3 columns)을 포함해야 한다:

- `Url` : DCinside 게시글 URL
 - URL은 반드시 DCinside 갤러리의 게시글 URL이어야 한다
- `Artist` : 아티스트 이름
- `Month` : 게시글 작성 월

Important

예.

```
Url,Artist,Month
https://gall.dcinside.com/board/view/?id=artist&no=1234567,아이유,2024-03
https://gall.dcinside.com/board/view/?id=artist&no=7654321,IU,2024-02
```

4. Run scrapy

```
scrapy crawl dcinside -a csv_file=path_of_url_file
```

Important

Url.csv 파일을 프로젝트 Root 디렉터리의 data 폴더에 저장했기 때문에, 파일명이 **urls.csv** 라고 가정하면 **path_of_url_file** 은 다음과 같다

- data/urls.csv

수집한 데이터가 자동으로 프로젝트 Root 디렉터리의 **result.csv** 파일에 저장된다

- result.csv

따라서 위의 전제를 바탕으로 Scrapy crawler를 실행하는 명령어는 다음과 같다:

```
scrapy crawl dcinside -a csv_file=data/urls.csv
```

⚠ Caution

Scrapy는 자동으로 result.csv 파일을 생성하며, 처음 크롤러를 실행할 때 동일한 디렉터리에 같은 이름의 **result.csv** 파일이 존재하지 않도록 주의해 주세요.

5. Resume the crawling process

크롤링이 중단되었을 경우, 동일한 명령어를 재실행하면 Scrapy가 tmp/ 디렉터리의 데이터를 바탕으로 크롤링 대기열과 상태를 자동으로 복구하여 작업을 이어서 진행한다.

예. 복구하려면 아래 명령 재실행

```
scrapy crawl dcinside -a csv_file=data/urls.csv
```

📌 Important

복구 실행의 경우에는 데이터 중간에 새 Column name행 자동으로 생성되며, 데이터 처리할 때 삭제하면 된다.

